

REDES NEURAIS ARTIFICIAIS

A tecnologia de redes neurais procura processar informações do mesmo modo como o cérebro humano o faz. Para tanto, utiliza processos e métodos nada convencionais. Lança a sua fundamentação fazendo analogias entre células nervosas vivas e o processo eletrônico, enfatizando o *aprendizado* como forma de captação de conhecimento. Conceitos como *aprender* e *treinamento* são uma constante do início ao final deste trabalho.

Graças a esse novo comportamento, computadores tem sido treinados para tarefas nas áreas de reconhecimento de padrões, previsões e controles diversos. Apesar da aplicação dessa tecnologia ser, ainda, um tanto tímida, possui, com certeza, um vasto campo de aplicações. Poder-se-ia citar, entre outras aplicações, o controle de qualidade, a previsão de preços de ações, o reconhecimento de vozes e imagens, a determinação de diagnósticos diversos, ...

Em "Redes Neurais Artificiais", Tafner, Xerez e Rodrigues Filho reúnem, de uma maneira bastante didática, os aspectos fundamentais para o entendimento e o uso de redes neurais.

Trata-se de uma obra que consegue reunir, desde aspectos teóricos básicos, até detalhes importantes de implementação de uma rede neural.

editora
EKO


EDITORA DA
FURB

ISBN 85-7114-050-2



9 788571 140509

006.3
T124r
TAF

Ex.2

N.Cham. 006.3 T124r TAF
Autor: Tafner, Malcon A.
Título: Redes neurais artificiais : int



3874101


Ac. 169017

Ex.2 BCCO PT

editora
EKO

REDES NEURAIS INTRODUÇÃO E PRINCÍPIOS DE NEUROCOMPUTAÇÃO ARTIFICIAIS

Malcon A. Tafner, Marcos de Xerez e Ilson W. Rodrigues Filho



editora
EKO


EDITORA DA
FURB

Este livro
gem amp
redes neu
com uma
técnicas d
suas poss
no prese
Aborda,
influência
natureza
considera
em segui
nhos con
redes neu
sua criaçã
ressurgim
pois de c
descaso c
ciar uma
nos neur
uma peq
respeito d
seus neu
plexas es
leitor tem
pios, a fu
tetura da
então, é r
formação
cial, que s
neurônios
ral artific
ainda, sit
cópias.
projeto d
todas as
organizac
de seleçã
conjunto
efetuar o
Expõe a
proporçã
de uma i
cadêmica
orientada
neural, id
bustos, m
implemen
enta doi
redes neu
plos de t
nesmos.
o um e
e apren
eural im

EDITORA
EKO

CEFET/ES - BIBLIOTECA
UNED - Colatina

Registro nº 388
Data 08.02.00


EDITORA DA FURB

© Copyright Malcon A. Taffner, Marcos de Xerez e
Ilson W. Rodrigues Filho, 1995

Editora da FURB
Rua Antônio da Veiga, 140. Bloco T, sala 117.
89012-900 - Blumenau SC - BRASIL
Fones: (047) 321-0329 / 321-0330 - Fax: (047) 322-8818

EDITORA EKO
Rua Dr. Amadeu da Luz, 260 - 89010-160 - Blumenau - SC - Brasil
Fone: (047) 326-0499 - Fax: (047) 326-3062
E-mail: alemaeko@nutecnet.com.br

Capa e Editoração Eletrônica:
VANGUARDA PRODUÇÕES & MARKETING
Rua Visconde de Mauá, 54 - Fone: (047) 322-4590 - Blumenau - SC

Distribuição: Editora da FURB e Editora Eko

Depósito legal na Biblioteca Nacional, conforme decreto nº 1825,
de 20 de dezembro de 1907.

"Impresso no Brasil / Printed in Brazil"

FICHA CATALOGRÁFICA

Elaborada pela Biblioteca Central da FURB

Tafner, Malcon Anderson
T124r Redes neurais artificiais: introdução e princípios de neurocomputação /
Malcon A. Tafner, Marcos de Xerez e Ilson W. Rodrigues Filho. - Blumenau : EKO :
Ed. da FURB, c1995.
199p. : il.
ISBN 85-7324-030-X (EKO)
ISBN 85-7114-050-2 (FURB)
Inclui bibliografia e índice.
1. Redes neurais (Computação). 2. Inteligência artificial. I. Xerez, Marcos
de. II. Rodrigues Filho, Ilson Wilmar. III. Título.

CDD 006.3

CEFET/ES - BIBLIOTECA
UNED - Colatina

AGRADECIMENTOS

Professor Ricardo Miranda Bárcia, PhD

Professora Aurora Akiko Kawahara, Dra.

Eng. Marcos Teixeira Pochmann

Professor Olívio Pedron

Coordenação de Aperfeiçoamento de Pessoal

de Ensino Superior - CAPES

Universidade Regional de Blumenau - FURB

e

Universidade Federal de Santa Catarina

(Programa de Pós-graduação em Engenharia de Produção)

Dedicado

à

Marilyn Ítala Tafner

3

PRINCÍPIOS DA NEUROCOMPUTAÇÃO

Neurocomputação e os computadores de Turing

Apesar de um rede neural poder ser simulada e executada em um computador sequencial, a rede está muito mais para o funcionamento cerebral do que para um computador convencional.

Uma rede neural artificial, conforme definição de TEUVO KOHONEN, um importante pesquisador finlandês de redes neurais, é: "uma rede massivamente paralela interconectada de elementos e suas organizações hierárquicas que, estão intencionadas para interar com objetos do mundo real do mesmo modo que um sistema nervoso biológico faz".

O modelo neurológico é programado para aprender. Essa palavra (aprender) soa estranho aos ouvidos dos profissionais de informática, pois desde o primeiro curso que fizeram, foi dito e repetido, que um computador faz apenas aquilo que for mandado fazer, ou seja, um computador apenas executa ordens para as quais ele foi previamente e devidamente programado. Esse tipo de tecnologia, a dos computadores atuais, é chamada de computadores baseados em Turing. Alan Turing, um matemático britânico, postulou uma abstração, agora conhecida como a Máquina de Turing, onde seu funcionamento é equivalente a qualquer computador.

A tese de Turing, chamada de "Sobre Números Computáveis", diz que qualquer processo que possa ser chamado de procedimento efetivo pode ser realizado pela sua máquina. Um procedimento efetivo é um conjunto de regras formais que descrevem, de momento para momento, precisamente que operação realizar. Outro tipo de associação aos modernos computadores é também creditada à John Von Neumann, principalmente, pela criação das memórias.

QUADRO 6- Quem foi John Von Neumann e Alan Turing

Inglês de nascença, Alan Turing, enquanto estudava matemática na Universidade de Cambridge, em 1936, escreveu uma dissertação com o nome de "Sobre Números Computáveis". Esse trabalho descreve todo um sistema de funcionamento dos computadores modernos, evidentemente de uma forma básica.



Fig. 12- Alan Turing

No fim do século XIX, os matemáticos haviam criado o "first order predicate calculus" (cálculo de predicado de primeira ordem), que era um simbolismo para a demonstração de teoremas matemáticos. Era um sistema de regras simples para manipulação de símbolos. Turing criou a sua máquina abstrata para tentar demonstrar que os problemas que pudessem ser resolvidos pelo cálculo dos predicados de primeira ordem poderiam ser resolvidos por métodos mecânicos. A partir dessa idéia, escreveu uma dissertação que demonstra um instrumento hipotético (chamado atualmente de Máquina de Turing) que desempenha operações lógicas. Operações de ler, escrever e apagar símbolos em uma fita sem fim.




Fig 13- A máquina de Turing.

A finalidade de seu trabalho não era inventar um computador, mas fazer a descrição de problemas não legítimos, ou seja, não passíveis de resolução lógica. Seu trabalho acabou aperfeiçoando certas características dos computadores modernos.

Esse cientista, Turing, foi o primeiro a ser recrutado pelo governo britânico para desenvolver um computador eletrônico. Alan Turing havia participado do projeto de uma máquina altamente secreta usada na segunda guerra para decifrar códigos alemães, chamada Colossus. A Inglaterra, durante a segunda guerra, construiu um total de 10 Colossus para decifrar os códigos alemães e teve uma atuação considerada excepcional.

Turing, teve acesso a um artigo escrito por um matemático chamado John Von Neumann (residente nos Estados Unidos) que descreve um projeto ligado a um computador eletrônico chamado EDVAC (um aperfeiçoamento do computador americano ENIAC) e, dessa forma, iniciou um projeto chamado ACE (Automatic Computing Engine), muito parecido com o projeto EDVAC. Turing abandonou o projeto ACE devido a uma frustração com entraves burocráticos. Seu próximo estágio foi compor uma equipe liderada por Max Newman na Universidade de Manchester. Newman também havia colaborado no projeto do Colossus e, junto com uma equipe, já havia construído um pequeno protótipo de um computador eletrônico com programa em memória chamado de Manchester Mark I.




Fig. 14- Colossus

Quanto ao matemático John Von Neumann, húngaro de nascimento e de renome internacional na década de 40, entrou para a história da computação quase por acaso. Neumann trabalhava no projeto de armas nucleares para o governo americano durante a segunda guerra e, enquanto esperava um trem na estação de Aberdeen, em 1945, encontrou-se com Herman Goldstine, um membro da equipe de desenvolvimento do ENIAC (Eletronic Numerical Integrator and Calculator), conhecido mundialmente hoje como o primeiro computador eletrônico.



Fig. 15- John Von Neumann

Quando Goldstine contou lhe das incríveis velocidades que esperava obter com o ENIAC, Neumann ficou impressionado e revelou à Goldstine que sentia-se tolhido pelo tempo que levava para conferir seus cálculos, todos de alta matemática.




Fig. 16- ENIAC

A partir desse encontro que teve com Goldstine, Neumann não levou muito tempo para entrar como consultor especial na equipe do ENIAC, e levou, consigo, o conceito vital do *programa armazenado*, elaborando um ensaio de 101 páginas intitulado "Preliminary Discussion of the Logic Design of an Eletronic Computing Instrument" (Esboço preliminar de um projeto lógico de um instrumento eletrônico de computação), para ser lido, avaliado e revisado pela equipe do EDVAC (Eletronic Discrete Variable Automatic Computer).

Basicamente, Von Neumann propôs construir computadores que:

- *A CPU deve ter uma memória separada, de onde obtém os seus dados.
- *O programa deve ser armazenado na memória, junto com os dados.
- *A máquina possui um registrador especial, utilizado para armazenar o endereço da próxima instrução a ser executada.

O ENIAC foi ligado em fevereiro de 1946 depois de 2 anos de desenvolvimento. Esse computador, pesando 30 toneladas, 170 metros quadrados, 10.000 capacitores e consumindo 150.000 Watts, possuía um total de 19.000 válvulas e queimava o mesmo número de válvulas em 1 ano. Até aquele momento, nenhuma máquina tinha sido criado com mais de 2.000 válvulas.

Os modelos neurais, procuram aproximar o processamento dos computadores ao cérebro. As redes neuronais, possuem um grau de interconexão similar a estrutura do cérebro, um método que certamente não é empregado em computadores convencionais.




Fig 17 - Em um computador convencional moderno, a informação é transferida em tempos específicos dentro de um relacionamento com o sinal de clock (sincronismo).

Aprender é uma capacidade que a rede possui graças aos seus neurônios. O neurônio biológico possui características não algorítmicas e, dessa forma, não aplica princípios digitais ou circuitos lógicos.




Fig 18 - Modelo neural.

Se uma rede aprende, ela, obviamente, retém conhecimento. O seu conhecimento não está localizado em um endereço e, dessa forma, a rede não separa memória de dados armazenados. O conhecimento armazenado está distribuído por toda a rede. Da mesma forma que não se pode dissecar um cérebro para extrair conhecimento, projetistas de redes neurais não podem simplesmente olhar os neurônios e dizer onde a informação está armazenada.

Mas, o que é exatamente aprender? Buscando uma definição mais adequada, significa, conforme um respeitado dicionário de língua portuguesa, "tomar conhecimento de; reter na memória, mediante o estudo, a observação ou a experiência; tornar-se apto ou capaz de alguma coisa, em consequência de 'estudo', observação ou experiência."

Dentro deste conceito, pode-se ter uma idéia mais clara sobre o termo aprendizado de uma rede neural e o que significa isso para a rede. A rede retém conhecimento dentro de si através do "estudo", da observação e da experiência.

Se um programa está previamente condicionado para tal atividade, jamais fará outra coisa senão a atividade já estabelecida. Desse modo, um programa de computador, nunca fará nada que já não saiba fazer.

Se escrevêssemos um programa para realizar uma ação diante de uma situação, teríamos que prever todas as situações possíveis para associar as ações pertinentes à cada ação. Porém, como todos sabem, existem certos casos que, simplesmente não é possível prever exatamente todas as situações, a começar pela quantidade fantástica de situações diferentes que possam vir a ocorrer dependendo do problema. Dessa forma, quando acontecesse uma dessas situações inesperadas, o nosso programa de computador, certamente, ou tomaria também uma atitude inesperada, ou não tomaria atitude nenhuma, pois não saberia o que fazer. A culpa não é do programa pois não foi programado para reagir diante de situações que ainda não lhe foram apresentadas, e muito menos do computador.

O cérebro não pensa assim, pois, baseado no conhecimento sinápticamente acumulado, tomará alguma ação perante a nova situação, ponderando pelo julgamento dos elementos que aprendeu terem relevância.




Fig 19- O Neurônio Biológico

Dentro deste contexto, a definição e o estudo das redes neurais, teve a sua origem e fundamentação baseadas no estudo do cérebro e de suas conexões sinápticas.

O cérebro humano consome de 20 a 25% da energia corporal e possui um total de 10 bilhões de neurônios, sendo que cada um faz entre mil e dez mil conexões com os neurônios adjacentes. Se fosse possível um chip reproduzir essas conexões, teria aproximadamente 5.000 m².

O aprendizado sináptico é massivamente paralelo o que o torna flexível, rápido e eficaz. Traçando um comparativo entre o cérebro e o computador, resulta no quadro abaixo os seguintes valores.

Quadro comparativo entre o cérebro e o computador

Parâmetro	Cérebro	Computador
Material	Orgânico	Metal e plástico
Velocidade	Milissegundo	Nanosegundo
Tipo de processamento	Paralelo	Sequencial
Armazenamento	Adaptativo	Estático
Controle de processos	Distribuído	Centralizado
Número de elementos processados	10e 11 a 10e 14	10e 5 a 10e 6
Ligações entre elementos processados	10.000	< 10

O mesmo paralelo pode ser traçado comparando o computador, como o é conhecido tradicionalmente, com as redes neurais, obtendo dessa comparação um resultado bastante interessante. Para tanto, a comparação não se dará com um computador específico encontrado no mercado, mas sim com o paradigma predominante nos computadores atuais. O atual paradigma, criado por John Von Neumann, estabelece o uso de memórias (veja Quadro abaixo).

Quadro comparativo entre computadores e neurocomputadores

Máquinas de von Neumann	Neurocomputadores
Executa programas	Aprende
Executa operações lógicas	Executa operações não lógicas, transformações, comparações
Depende do modelo ou do programador	Descobre as relações ou regra dos dados e exemplos
Testa uma hipótese por vez	Testa todas as possibilidades em paralelo

Como atual substituto eletrônico do neurônio biológico (figura 20), o neurônio artificial possui o seguinte formato:




Fig 20- Neurônio Artificial

As conexões entre os neurônios procuram simular as conexões sinápticas biológicas fazendo uso de uma variável chamada peso. A função de soma acumula os dados recebidos (estímulos) de outros elementos, e a função de transferência processa a função soma transformando-a.

Biologicamente falando, um neurônio passa adiante um estímulo conforme a força dos estímulos recebidos provenientes dos neurônios que, com ele, estão conectados. No mundo artificial, o mesmo efeito é simulado, dentro das possibilidades tecnológicas atuais.

A soma dos impulsos recebidos é que determina a continuação do estímulo recebido.




Fig 21- A conexão sináptica artificial

O tipo de conexão, número de camadas de neurônios e o tipo de treinamento são os aspectos que diferem os tipos de redes neurais. Entre os modelos já publicados em revistas especializadas, encontram-se, como clássicos, os modelos: Backpropagation, Hopfield, Kohonem, Perceptron, Boltzman e outros.

Fundamentos das redes neurais

Os conceitos de redes neurais estão datados desde a década de 40, o que significa que, na época, não haviam computadores, não como os que conhecemos hoje. Deduz-se, então, que as redes neurais independem de computadores para funcionarem, da mesma forma que um projetista de casas (um engenheiro por exemplo) independe de um computador para realizar os seus projetos. Contudo, é certo que um bom sistema de CAD (Computer Aided Design) ajudará reduzindo o tempo de elaboração do projeto de forma significativa, além de aumentar a qualidade do trabalho final. O tempo e a qualidade são aspectos de relevância significativa na era moderna, não só em computação ou engenharia, mas praticamente em todas as ciências conhecidas.

QUADRO 7 - Neurônios artificiais eletrônicos

Muitos outros trabalhos publicados também têm demonstrado uma certa tendência eletrônica dentro do processo. Conforme a figura extraída do livro "Methods in Neuronal Modeling", podemos verificar que muitos autores se esforçam e se orientam no sentido de substituir o atual processo computacional por um processo neurológico, ou eletro-neurológico.




Fig. 22 - Neurônios eletrônicos

Neste trabalho, na figura 22, KLEINFELD e SOMPOLINSKY, propõem um circuito que modele uma rede neural eletrônica análoga ao processo biológico. Os neurônios são representados pelo saturamento de amplificadores (os triângulos) e as conexões sinápticas entre cada par de neurônios são representadas pela condutância proporcional para componentes sinápticos rápidos ou componentes sinápticos lentos.

Para o caso de redes neurais, embora a situação não seja exatamente a mesma, é muito parecida. No início (na década de 40), os modelos de redes neurais eram calculados com papel e lápis na mão, talvez até uma caneta tinteiro. Hoje, esses mesmos modelos são jogados para dentro de um computador e esperado o resultado do processamento do modelo. Esse processamento antes era feito totalmente a mão, o que poderia significar incontáveis horas de cálculo, para não dizer impraticáveis.

A máquina (o computador atual) pode realizar todas as iterações necessárias à solução do problema, e, ainda, fornecer toda uma estatística sobre como está se procedendo o aprendizado da rede. Pode, também, permitir que o usuário do sistema interfira na rede neural quando e como quiser, mudando, por exemplo, os pesos das conexões da rede, e, em seguida, continuar o processamento do modelo neural. Enfim, as possibilidades são muitas e infinitamente confortáveis para o projetista da rede neural. Essa facilidade de articulação associada à rapidez de processamento, faz com que o computador seja o maior aliado ao processamento de redes neurais artificiais.

Uma rede neural, como o próprio nome sugere, é uma coleção de neurônios dispostos de forma que configurem um aspecto específico. É com estes neurônios que a rede neural aprenderá as informações que serão fornecidas pelos canais de entrada dos neurônios. O aprendizado está distribuído por toda a rede, ou seja, por todos os neurônios. Antes de explicarmos o funcionamento geral de uma rede, fiquemos atentos ao funcionamento do neurônio em particular.

O Neurônio Artificial

O neurônio artificial possui muitos nomes diferentes na bibliografia atual. Entretanto, todos esses nomes estão intencionados a expor o mesmo elemento em questão, porém com o título alterado conforme o autor. Entre os sinônimos mais conhecidos encontramos: elemento de processamento e nodo. De qualquer forma, esses neurônios possuem, na sua estrutura e funcionamento, uma similaridade muito grande com os conhecidos neurônios biológicos.

Sinais de entrada e saída

O neurônio possui, a princípio, um ou mais sinais de entrada e um sinal de saída. Sua semelhança com um neurônio biológico é muito grande pois, ambos os neurônios possuem disparos de saída podendo receber muitas entradas.




Fig. 23- Neurônio Artificial simples com n entradas e uma saída

As entradas de um neurônio artificial podem ser comparadas exatamente como estímulos para o neurônio natural. Todos esses estímulos são trazidos até o neurônio simultaneamente, ou seja, se um neurônio possuir 5 entradas, os sinais das 5 entradas deverão chegarão até o núcleo de processamento ao mesmo tempo, isto quer dizer, paralelamente.




Fig. 24- Neurônio com 5 entradas

O processamento paralelo em computadores sequenciais (por exemplo, os microcomputadores atuais) pode ser paradoxal, mas não o é, ocorre de fato. A simulação de um ambiente paralelo é possível, e é desta forma que ocorre esse tipo de processamento para as redes neurais. O modelo matemático simula o paralelismo da rede neural através de um algoritmo.

Pesos

Quanto aos pesos, atributo importantíssimo do neurônio, podemos compará-los com os dendritos realizando as suas sinapses em outros neurônios. Graças a essa comparação, os pesos são chamados de pesos sinápticos. Os pesos, representados por w (weight - peso), são valores que representam o grau de importância que determinada entrada possui em relação àquele determinado neurônio. Ou seja, esse valor (o peso), muda em função da intensidade do sinal de entrada, e dessa forma, o peso muda o seu valor representativo para a rede. Significa que, quando uma entrada é bastante estimulada, acaba estimulando, também, o peso correspondente à sua conexão. Um peso quando é bastante estimulado, automaticamente terá, cada vez mais, mais influência no resultado do sinal de saída.

Os pesos podem ser vistos, matematicamente, como um vetor de valores ($w_1, w_2, \dots, w_n$). Havendo mais de um neurônio na rede, podemos então ter uma coleção de vetores, ou seja, uma matriz de pesos, onde cada vetor, corresponde a um neurônio. Quando as entradas ($x_1, x_2, \dots, x_n$) são apresentadas para o neurônio, elas são multiplicadas pelos pesos, e a soma desses resultados é, então, o sinal de excitação no neurônio. As entradas multiplicadas pelos pesos, recebem, depois desta operação, o nome de entradas ponderadas (unidade SIGMA - Σ).




Fig. 25 - Um neurônio com entradas e pesos definidos

A função do neurônio é, depois de acumulado o valor somado dos produtos ocorridos entre as entradas e os pesos, comparar esse valor com um limiar (um valor estipulado), e, atingindo-o, o valor é então passado adiante através da saída. A esse processo chamamos

de função de transferência. Caso contrário, se o valor não atinge o limiar, o sinal não é transferido adiante. Em ambos os casos, com sinal ou sem sinal, a resposta é significativa, pois afetará diretamente, ou a resposta final da rede, ou os neurônios da próxima camada. A lógica neural expõe, que a intensidade dos sinais de entrada, dispara, ou não, o sinal do neurônio, fazendo com que este estimule o neurônio seguinte.

Função de Ativação e Função de Transferência

Temos agora duas funções diferentes, a função de ativação e a função de transferência. A função de ativação antecede a função de transferência, e tem por atribuição, repassar o sinal para a saída do neurônio. A função de ativação é uma função de ordem interna, cuja atribuição é fazer acontecer um nível de ativação dentro do próprio neurônio, ou seja, é uma decisão tomada pelo neurônio sobre o que fazer com o valor resultante do somatório das entradas ponderadas. Essa decisão terá um efeito restrito ao próprio neurônio.




Fig. 26 - Função de ativação e função de transferência

Em modelos simples de redes neurais, a função de ativação pode ser a própria função de soma das entradas ponderadas do neurônio. Em modelos mais complexos, a função de ativação possui um processamento atribuído. Esse processamento, pode usar, por exemplo, o valor prévio de saída como uma entrada para o próprio neurônio (uma auto-excitação). Após o valor ter sido processado pela função de ativação, é então passado para a função de transferência que produzirá o valor de saída do neurônio.

A função de transferência pode ter muitas formas e métodos, podendo ser simples ou complexa. A função de transferência também é conhecida como limiar lógico (threshold). Essa função é quem define e quem envia para fora do neurônio o valor passado pela função de ativação. Se fossemos comparar uma função de transferência com um circuito elétrico, teríamos o esquema da figura 27.





Fig. 27 - Limiar lógico

Contudo, em alguns modelos de redes, o nível de saída produzido pela função de transferência é igual ao nível de ativação. Muitas vezes, essa função possui características sigmas ou ríspidas, assim, o neurônio pode não produzir efeito no neurônio seguinte se o valor de ativação estiver abaixo de um valor mínimo para sua ativação. As funções de transferências mais conhecidas são :



Algumas vezes a saída do neurônio é conduzida para outros neurônios, em vez de ser conduzida como resposta final, ou seja, os sinais de saída vão para o mundo real, e não para uma próxima camada. Existem também redes que conduzem as saídas dos neurônios para ambos os sentidos, como uma retroalimentação, ou seja, a saída do neurônio afeta ele próprio (auto-excitação).

As funções de rampa e limite possuem decisões ríspidas, principalmente para valores extremos. Essas funções refletem a saída dentro de uma faixa (digamos entre 0 e 1). Isto quer dizer que, ultrapassando um certo limite, a função dispara o valor 0, ou 1, ou -1, dependendo da função e da forma que será utilizada.

As funções sigmóides são utilizadas normalmente para decisões onde as saídas limites são disparadas quando existe uma saturação muito alta do valor de ativação. Em outras palavras, significa, que se estivessemos utilizando a função sigmóide $y = 1/(1+e^{-x})$, essa função produziria um 0 de saída somente quando o valor passado da função de ativação tivesse um grande valor negativo, e produziria o valor de saída 1 quando a ativação tivesse um grande valor positivo. Essa função faz a transição entre os extremos de forma suave.

O neurônio artificial completo

Agora que o neurônio possui todos os seus aspectos, características, funções e valores, podemos considerá-lo como completo, restando apenas comentar sobre as estruturas das redes de neurônios, chamadas de redes neurais. O neurônio, a partir deste momento pode assumir seu símbolo universal, demonstrando em seu interior as duas peças chaves para o seu perfeito funcionamento: A função de soma (Σ) e a função de transferência (T). Consideraremos a função de ativação igual a função de soma.




Fig. 28- Neurônio completo

A rede neural

Combinando diversos neurônios podemos formar o que é chamado de rede de neurônios, ou uma rede neural para simplificar. As entradas podem ser conectadas em muitos neurônios com vários pesos, resultando assim em uma série de saídas, uma para cada neurônio. Essas conexões, em comparação com o sistema biológico, representam o contato dos dendritos com outro neurônio formando a sinapse.




Fig. 29- Analogia entre os neurônios naturais e os neurônios artificiais

Para o caso de haver mais de uma saída, ou melhor, diversos pontos de saída que combinados representem determinada ação ou objetos do mundo real, deverão haver, também, o mesmo número de neurônios. Por exemplo, havendo 3 saídas para 5 entradas, haverá um total de 3 neurônios na camada de saída com 5 pontos de entrada, que, distribuídos, alimentam todas as saídas. Esse tipo de estrutura é chamado de uma rede amplamente conectada.




Fig. 30- Rede amplamente conectada

A camada de entrada tem esse nome apenas como figurativo, pois, sua única função é armazenar a informação de entrada para ser passada para a camada seguinte de neurônios. Essa camada, pode ser chamada também de ponto de entrada, ou camada de distribuição, ou, ainda, de neurônios de entrada. Normalmente possui um nome

diferente de neurônio para que não seja confundido com neurônios de processamento. Essa dupla identidade faz com que muitas vezes possuam um aspecto neural.

Camadas escondidas (ocultas)

Outro detalhe importante das redes neurais, é que podem possuir camadas escondidas (hidden), também chamadas de intermediárias ou ocultas. Essas camadas intermediárias, se situam entre a camada de entrada e a camada de saída da rede neural. Não existe uma regra que defina o número de camadas escondidas. Esse número pode variar de 0 até n camadas. Essas camadas são compostas por neurônios, que possuem exatamente a mesma estrutura que os neurônios da camada de saída. Sua única diferença é não ter contato com o mundo externo, e, assim, os sinais são passados para os outros neurônios obedecendo as regras de transferência de cada neurônio. O número de neurônios da camada escondida é livre, não obedecendo nenhuma regra específica.




Fig. 31- Redes exemplificando camadas escondidas

Arquitetura da rede

As conexões entre as camadas podem gerar n números de estruturas diferentes. A conexão em si é tornar o sinal de saída em um sinal de entrada, tanto para um outro neurônio quanto para o mesmo que o gerou. Quando uma rede possui todas as saídas dos neurônios de uma camada conectadas com todos os neurônios da próxima camada é chamada de *fully connected* (amplamente conectada).




Fig. 32- Redes fully connected

Quando o sinal de saída de um neurônio servir como entrada para a mesma camada, ou uma camada anterior, a rede, então, possui uma característica chamada de *feedback* (realimentação).




Fig. 33- Redes feedback

O sinal pode ser usado tanto para excitar a camada inteira como também para excitar apenas um neurônio em particular, ou até mesmo, o próprio neurônio, que realizou o disparo.

Outro tipo de conexão pode ser, por exemplo, entre camadas alternadas. Essa conexão pode ser realizada tanto para frente quanto para trás (realimentação). Também pode acontecer conexões de neurônios em partes específicas de uma camada qualquer.




Fig. 34- Um tipo de conexão entre camadas alternadas

Enfim, a arquitetura da rede neural é livre, podendo ser modificada conforme o gosto ou a necessidade do projetista.

Métodos de controle do aprendizado

A monitoração é o processo de controle do aprendizado da rede. Este processo de aprendizado acontece, basicamente, de duas formas: o aprendizado supervisionado (com professor) e o aprendizado não-supervisionado (sem professor).

- Aprendizado Supervisionado

Em aprendizado supervisionado, a rede neural é treinada com o auxílio de um professor, ou um treinador. Para tanto, a rede deverá possuir pares de entrada e saída, ou seja, um conjunto de entradas e um conjunto com as saídas desejadas para cada entrada. Toda vez que for apresentada à rede uma entrada, deverá ser verificado se a saída obtida (gerada a partir dos cálculos efetuados com os pesos que a rede possui) confere com a saída desejada para aquela entrada. Sendo diferente, a rede deverá ajustar os pesos de forma que armazene o conhecimento desejado. Essa iteratividade do treino deverá ser repetida com todo o conjunto de treinamento (entradas e saídas), até que a taxa de acerto esteja dentro de uma faixa considerada satisfatória. Essa forma de aprendizado é bem conhecida e tem demonstrado excelentes resultados em aplicações reais.

- Aprendizado Não-Supervisionado

Este tipo de aprendizado também é conhecido como aprendizado auto-supervisionado. Esse aprendizado não requer saídas desejadas, e por isso é conhecido pelo fato de não precisar usar professores para o seu treinamento. Para o treinamento da rede, são usados apenas os valores de entrada. A rede trabalha essas entradas e se organiza de modo que acabe classificando-as, usando, para isso, os seus próprios critérios. Esse tipo de rede utiliza os neurônios como classificadores, e os dados de entrada, como os elementos para classificação. O processo de classificação fica a encargo da rede neural e o seu algoritmo de aprendizado. A auto-organização demonstrada em redes neurais não-supervisionadas, envolve, o processo de competição, e o processo de cooperação entre os neurônios da rede. Muitos pesquisadores têm utilizado esse tipo de rede como detector de características, dada a sua capacidade de aprender a discriminar

estímulos ocorrendo em partes espacialmente diferentes. Em outras palavras, pode-se dizer que, a rede, pode aprender a distinguir a esquerda e a direita sem a presença de um professor para lhe ensinar.

O Ajuste Sináptico

O ajuste sináptico é o aprendizado em cada neurônio do fato apresentado. Ou seja, cada neurônio, conjuntamente com todos os outros, representa a informação que atravessou pela rede. Nenhum neurônio guarda em si todo o conhecimento, mas faz parte de uma malha que retém a informação graças a todos os seus neurônios. O conhecimento dos neurônios reside nos pesos sinápticos. Tanto é verdade essa afirmação, que, nos EUA, existe uma discussão sobre patentes de redes neurais. No caso, a patente se orienta no sentido de registrar a combinação sináptica, ou seja, os valores dos pesos.

O ajuste é realizado em função de um cálculo que aponta a quantidade de erro do resultado (saída). Esse ajuste procura corrigir os pesos de modo que se produza a saída desejada diante da respectiva entrada.

Expondo um método bastante simples, podemos explicar como acontece o ajuste, e de que forma a rede aprende nos pesos sinápticos. O ajuste sináptico é resultado de um cálculo matemático. Esse cálculo visa somar ao peso atual, um valor que corresponda a quantidade de erro gerada pela rede, e desta forma corrigir o valor do peso. Existem muitos tipos de cálculos para este fim. O mais encontrado é o cálculo chamado de "Regra Delta". Esta regra possui o seguinte formato:

$$w_i(n+1) = w_i(n) + \Delta_i \quad e$$

$$\Delta_i = c * \delta * x_i,$$

onde: Δ_i = correção associada com a i -ésima entrada x_i

$w_i(n+1)$ = o novo valor do peso

$w_i(n)$ = o valor velho do peso

δ = saída desejada - saída obtida

c = constante de aprendizado

(normalmente é 1 quando a rede opera com valores binário)

Exemplo de ajuste sináptico

Vamos trabalhar com um exemplo simples para entender quando, como e onde aplicar a Regra Delta em um ajuste dos pesos. Uma rede neural funciona aplicando uma entrada X qualquer, e como resposta, nos apresenta uma saída Y , gerada a partir da entrada X , e dos pesos que nela estão contidos. Sabemos que a saída está correta comparando o resultado obtido com o resultado esperado (para redes supervisionadas). Caso a saída esteja correta, ou seja, as respostas da comparação coincidem, podemos, então, testar a próxima entrada X . Porém, se a saída obtida estiver diferente da saída desejada, considera-se, então, como errada. Esse resultado força uma modificação dos pesos para que se produza a saída desejada.

O erro é calculado da seguinte forma (Regra Delta):

Constante = 1

Erro = saída esperada - saída obtida

Peso Novo = Peso Antigo + (Erro * Entrada * Constante)

Vamos imaginar que a nossa rede neural possua apenas um neurônio com duas entradas, e desejamos fazer com que ela aprenda as seguintes funções :

Entrada = {1,1} deverá produzir a saída = {1} e

Entrada = {0,0} deverá produzir a saída = {0}

Obs.: Poderia-se atribuir, por exemplo, funções robóticas aos resultados de 0 e 1, na saída. O movimento de um robô para caminhar poderia ser ativado pelo valor de saída 1, e o valor de saída 0 para fazer o robô parar. Podemos, também, em vez de trabalhar com valores binários simples e discretos, trabalhar com operações reais ligadas a esses resultados.

Dados os elementos acima, identificamos que a rede fará o aprendizado com o método de monitoração de aprendizado supervisionado. A rede deverá iniciar com os valores dos pesos pequenos escolhidos de forma randômica. Neste caso, podemos, arbitrariamente, iniciá-los com o valor 0, Pesos = {0,0}. A constante de aprendizado poderá iniciar com 1, sua explicação se dará em um momento mais propício.

Outro ponto a ser resolvido é, qual a função de transferência a ser utilizada? Para este caso utilizaremos a função de rampa, que, conforme o modelo gráfico, o esquema representativo e matemático é o seguinte:





Fig. 35 - Rede neural do exemplo

Se resultado < 0	então saída = 0
Se resultado = 0 ou resultado ≤ 1	então saída = entrada
Se resultado > 1	então saída = 1

Iniciando agora o treinamento da rede, apresentamos o primeiro fato do conjunto a ser aprendido pela rede, o fato {1,1}, e obtemos, como resultado, o valor 0.




Verificando que a saída 0 é diferente da saída desejada 1, realizamos, então, um ajuste sináptico:

Ajuste para o peso 1
 Erro = 1 - 0 = 1
 Peso Novo = 0 + (1 * 1 * 1) = 1


Ajuste para o peso 2
 Erro = 1 - 0 = 1
 Peso Novo = 0 + (1 * 1 * 1) = 1

Apresentamos para a rede o segundo fato do conjunto de treinamento para ser aprendido:




Sendo que o resultado esperado (0) é igual ao resultado obtido, não é necessário realizar um ajuste sináptico (como foi feito anteriormente), pois os pesos como estão representam esta informação de forma correta. O passo seguinte é realizar de novo o teste com o conjunto de treinamento, visto que no teste anterior houve um ajuste dos pesos. A idéia, é que quando não houver mais necessidade de ajustar os pesos para todo o conjunto significará que a rede aprendeu.

Passando agora o primeiro fato do conjunto novamente, obtemos o resultado correto:



Sendo o resultado obtido, de acordo com o resultado esperado, não é necessário realizar o ajuste dos pesos, podendo, então, seguir com o segundo fato do conjunto.



Como o resultado obtido, também, está de acordo com o resultado esperado, não há necessidade de realizar o ajuste. Podemos, a partir de agora, considerar esta rede treinada para reconhecer os conjuntos {1,1} e {0,0}.

É evidente que o exemplo trata de uma rede neural extremamente simples, com fatos simples e complexidade mínima. Mas ilustra, o processo de mudança dos pesos sinápticos.

O processo de treinamento

O processo de treinamento da rede, diferente do que se imagina, também é delicado.

O primeiro ponto a ser discutido, é que a rede não deve ser treinada 100% para cada fato, mas treinada com o conjunto inteiro, sendo apresentado as entradas várias vezes iterativamente. Caso a rede seja treinada 100% para um fato de cada vez, afetará, negativamente, o conhecimento de todos os fatos previamente aprendidos. Ou seja, implicará em esquecer alguma coisa do fato anteriormente apresentado, e assim, quando chegar ao final do conjunto de treinamento, muito provavelmente, a rede já terá esquecido o primeiro fato apresentado.

Quando um conjunto de entrada é apresentado à rede, esta pode acertar em uma determinada iteração, e errar na próxima. Esse fato se deve ao detalhe de, que quando a rede comete um erro durante a fase de treinamento, ocorrem mudanças para compensar o erro. Esta compensação poderá interferir com a habilidade da rede para produzir a resposta correta para o fato anterior. Em outras palavras, quando retornar um fato que a rede já acertou antes, poderá errar desta vez, devido aos ajustes feitos enquanto treinava os fatos seguintes. Dessa forma, o treinamento é um processo extremamente iterativo, onde, os fatos (conjunto de entrada), são apresentados à rede continuamente até que, então, acerte todos os fatos, ou, pelo menos, uma razoável percentagem deles.

Exemplo do treinamento iterativo :

- 1 - Apresentar um fato a rede,
- 2 - Conferir o resultado e ajustar os pesos se necessário,
- 3 - Se não for o final do Conjunto de Treinamento, voltar ao passo 1 apresentando um novo fato,
- 4 - Se, terminado o conjunto de treinamento, e a rede ainda não estiver treinada de forma satisfatória, reiniciar o processo no passo 1 mantendo os pesos ajustados até o momento,
- 5 - A rede é considerada treinada.

Cada vez que é apresentado para a rede um novo fato, ela mudará alguma coisa, podendo convergir para o melhor ponto ou não. Quer dizer que, as vezes, insistir no treinamento, pode não ser uma solução inteligente, pois a rede poderá já estar na sua melhor forma, e a insistência do treinamento poderá desvirtuar todo o conhecimento já adquirido.

Comparando esse comportamento neural com a biologia, encontramos um paralelo muito estreito, para não dizer igual. Quando estudamos uma matéria para alguma prova, efetuamos esse estudo exatamente como o conceito explicado há pouco. Lemos e releemos diversas vezes até "fixar" no cérebro o conteúdo. É comum, quando alguém estuda, reler as páginas anteriores já lidas de um livro. Só porque a matéria já foi lida não significa exatamente que foi aprendida. Como exemplo, todos conhecemos e praticamos a famosa revisão antes de uma prova. No primário, as crianças, à medida em que vão aprendendo novas letras, vão conjuntamente, revendo as letras já aprendidas, ou seja, estão misturando a informação para que o aprendizado seja iterativo. Tudo isso tem o intuito de fixar a aprendizagem, tanto a nova, quanto a velha informação.

Não se deve apresentar um conjunto de treinamento ordenado, mas misturado, desordenadamente, pois apresentá-los ordenadamente seria como apresentar um fato de cada vez, e treinar a rede 100% para o fato apresentado.




Fig. 36- Apresentação dos fatos ordenadamente e constantemente

A figura acima mostra uma apresentação de fatos (cada retângulo é um fato) de forma ordenada pela cor em direção a uma rede neural. Pois bem, analisando o caso mostrado acima, primeiro a rede aprende a cor preta e ajusta os seus pesos para reter esse aprendizado. Depois, a rede deve aprender a cor cinza escuro, e novamente ajusta os seus pesos para captar essa nova informação. Nesse ajuste, as modificações serão muito constantes e contínuas, e a partir dessa insistência, também serão profundos os ajustes efetuados. Na terceira apresentação, o cinza claro, a rede, muito provavelmente, já terá esquecido o preto em virtude dos ajustes para o cinza escuro, e os novos ajustes para o cinza claro.




Fig. 37 - Apresentação dos fatos desordenadamente e recidivamente

Conforme a figura 37, os fatos são apresentados desordenadamente, e assim sendo, recidivamente. Para esta situação, acontecerá que, quando a rede já estava quase esquecendo a cor preta, ela aparece, e, assim, novamente, acaba reforçando o seu aprendizado (reforço sináptico).

A forma desordenada provoca uma soma dos ajustes para obter o conjunto completo treinado, enquanto, que a forma ordenada, literalmente, faz o novo fato passar por cima do fato anteriormente aprendido. A insistência, contínua e constante, de um fato, acaba forçando demais as sinapses em um sentido, fazendo com que se esqueça o que já havia aprendido antes (lavagem cerebral).

Bibliografia

- ALEKSANDER, I., MORTON H. *An Introduction to Neural Computing*. Inglaterra, Londres : Chapman & Hall, 1990.
- DAYHOFF, Judith. *Neural Network Architectures*. USA, New York : Van Nostrand Reinhold, 1990.
- HUGO, Marcel e TAFNER, Malcon PERCEP : uma implementação de um rede neural. In : I SEMINCO, Blumenau, maio/92. *Anais ... Blumenau : FURB*, 1992.
- KOHONEN, Teuvo. *An Introduction to Neural Computing*. Finland : Helsinki University of Technology, 1987.
- LAWRENCE, J. *Introduction to Neural Networks and Expert Systems*. USA, California : California Scientific Software, 1992.
- LIPPMANN, Richard . *An Introduction to Computing with Neural Works*. IEEE Computer Society, v. 3, n° 4, p. 4-22, abr. 1987.
- MASTERS, Timothy. *Practical neural Networks recipes in C++*. USA, California : Academic Press, 1993.
- RICH, Elaine. & KNIGHT, Kevin. *Inteligência Artificial*. São Paulo : Makron Books, 1993.

4

FASES DE UM PROJETO DE REDES NEURAIS

O projeto

A aplicação dessa tecnologia tem variado muito, mas, de uma forma geral, o objetivo é quase sempre o mesmo, reconhecer e classificar padrões, e, possivelmente, também prever e generalizar informações. Sabemos que um projeto utilizando redes neurais deve ser orientado para esse tipo de finalidade. Não poderíamos desenvolver um projeto dessa ordem para, por exemplo, cadastrar clientes de uma loja. Seria mais condizente, porém, aplicar esse tipo de tecnologia para classificar o perfil dos clientes cadastrados dessa loja. O campo de aplicação de redes neurais é extenso. Devemos tomar muito cuidado não somente ao aplicá-las, mas também com o onde, o como e o quando aplicá-las. A rede, apesar de vasta aplicação, possui seus limites e sua área específica de atuação.

Uma vez diante de um projeto de uma rede neural, não podemos mais pensar em procedimentos, regras ou fórmulas algorítmicas de processamento de dados, mas em tipos de dados de entrada, dados de saída e tratamento de dados (veja o capítulo sobre Formação do Conjunto de Treinamento).

A rede, baseada nos dados, terá dois momentos de explicitação do processamento: o momento de aprendizado e o momento de utilização (a aplicação da rede de fato). Devemos-nos atentar para o fato de que, esses dois momentos de operação de uma rede neural, apesar de serem próximos, são bem distintos e aplicados em períodos diferentes no projeto da rede. O aprendizado é um processo de ajuste dos pesos das conexões em resposta à quantidade de erros gerada pela rede. Ou seja, a rede possui a propriedade de modificar-se em função da necessidade de aprender a informação que lhe foi apresentada anteriormente. Já o processo de utilização é a maneira